

Hoeffding不等式

PAC学习模型

一致有限假设集情形

不一致有限假设集情形

不可知PAC学习

第四讲 概率近似正确学习框架

牟克典

2021年4月7日

Hoeffding不等式

PAC学习模型

一致有限假设集情形

不一致有限假设集情形

不可知PAC学习

概要

1 Hoeffding不等式

Chernoff界(1)

给定随机变量 X 和 $\epsilon > 0$, 对任意 $t > 0$,

$$\Pr[X \geq \epsilon] = \Pr[e^{tX} \geq e^{t\epsilon}]$$

由Markov不等式可知

$$\Pr[e^{tX} \geq e^{t\epsilon}] \leq \frac{1}{e^{t\epsilon}} E[e^{tX}].$$

因此

$$\Pr[X \geq \epsilon] \leq e^{-t\epsilon} E[e^{tX}].$$

Chernoff界(2)

- 基于不等式

$$\Pr[X \geq \epsilon] \leq e^{-t\epsilon} E[e^{tX}],$$

- 寻找 $E[e^{tX}]$ 的上界 $g(t)$;
- 选择 t 使得 $e^{-t\epsilon} g(t)$ 最小.
- 如何寻找 $E[e^{tX}]$ 的上界 $g(t)$?

Hoeffding引理

设 X 为满足 $E[X] = 0$ 且 $a \leq X \leq b$ 的随机变量, 其中 $a < b$, 则对任意 $t > 0$, 下列不等式成立:

$$E[e^{tX}] \leq e^{\frac{t^2(b-a)^2}{8}}.$$

Hoeffding不等式(1)

Hoeffding不等式

设 X_1, \dots, X_m 为一组独立随机变量且对任一 $i \in [1, m]$, X_i 在 $[a_i, b_i]$ 中取值. 令 $S_m = \sum_{i=1}^m X_i$, 则对任意 $\epsilon > 0$, 下列不等式成立:

$$(1.) \Pr[S_m - E[S_m] \geq \epsilon] \leq \exp\left(-\frac{2\epsilon^2}{\sum_{i=1}^m (b_i - a_i)^2}\right).$$

$$(2.) \Pr[S_m - E[S_m] \leq -\epsilon] \leq \exp\left(-\frac{2\epsilon^2}{\sum_{i=1}^m (b_i - a_i)^2}\right).$$

Hoeffding不等式(2)

证明: 应用Chernoff界技术, 可得

$$\Pr[S_m - E[S_m] \geq \epsilon] \leq e^{-t\epsilon} E[e^{t(S_m - E[S_m])}].$$

考虑到 X_1, \dots, X_m 的相互独立性, 则

$$E[e^{t(S_m - E[S_m])}] = \prod_{i=1}^m E[e^{t(X_i - E[X_i])}].$$

由Hoeffding引理可得 $E[e^{t(X_i - E[X_i])}] \leq e^{\frac{t^2(b_i - a_i)^2}{8}}$, 则

$$\Pr[S_m - E[S_m] \geq \epsilon] \leq \exp \left(-t\epsilon + t^2 \left(\sum_{i=1}^m \frac{(b_i - a_i)^2}{8} \right) \right).$$

Hoeffding不等式(3)

选择 $t = \frac{4\epsilon}{\sum_{i=1}^m (b_i - a_i)^2}$ 则得到 $\exp\left(-t\epsilon + t^2 \left(\sum_{i=1}^m \frac{(b_i - a_i)^2}{8}\right)\right)$ 的最小值

$\exp\left(-\frac{2\epsilon^2}{\sum_{i=1}^m (b_i - a_i)^2}\right)$. 因此可以得到

$$(1.) \Pr[\mathbf{S}_m - E[\mathbf{S}_m] \geq \epsilon] \leq \exp\left(-\frac{2\epsilon^2}{\sum_{i=1}^m (b_i - a_i)^2}\right).$$

同样方式可证明(2.) \square

Hoeffding不等式(4)

Hoeffding不等式：关于 $|S_m - E[S_m]| \geq \epsilon$ 的概率界

设 X_1, \dots, X_m 为一组独立随机变量且对任一 $i \in [1, m]$, X_i 在 $[a_i, b_i]$ 中取值. 令 $S_m = \sum_{i=1}^m X_i$, 则对任意 $\epsilon > 0$, 下列不等式成立:

$$\Pr[|S_m - E[S_m]| \geq \epsilon] \leq 2 \exp \left(- \frac{2\epsilon^2}{\sum_{i=1}^m (b_i - a_i)^2} \right).$$

Hoeffding不等式

Hoeffding不等式：关于 $\frac{1}{m}S_m - E[\frac{1}{m}S_m] \geq \epsilon$ 的概率界

设 X_1, \dots, X_m 为一组独立随机变量且满足 $0 \leq X_i \leq 1$, 则对任意 $\epsilon > 0$, 下列不等式成立:

$$(1.) \Pr[\frac{1}{m} \sum_{i=1}^m X_i - \frac{1}{m} \sum_{i=1}^m E[X_i] \geq \epsilon] \leq \exp(-2m\epsilon^2).$$

$$(2.) \Pr[|\frac{1}{m} \sum_{i=1}^m X_i - \frac{1}{m} \sum_{i=1}^m E[X_i]| \geq \epsilon] \leq 2 \exp(-2m\epsilon^2).$$

Hoeffding不等式

PAC学习模型

一致有限假设集情形

不一致有限假设集情形

不可知PAC学习

概要

1 Hoeffding不等式

2 PAC学习模型

- 输入空间 \mathcal{X} , 输出空间 $\mathcal{Y} = \{0, 1\}$.
- 概念 $c: \mathcal{X} \rightarrow \mathcal{Y}$ 是从 \mathcal{X} 到 \mathcal{Y} 的映射.
- 概念类 C : 我们希望学习的概念的集合.
- 输入空间 \mathcal{X} 中的所有样本相互独立且服从同一固定但未知的分布 D .

学习问题, 对学习者(学习算法) A :

- 它所考虑的所有可能的概念的集合为假设空间 H (未必与 C 相同).
- 训练数据集 $S = \{x_i\}_{i=1}^m$ 中的每个样例 x_i 都是依分布 D 独立同分布产生的, 其标记 $y_i = c(x_i)$.

学习算法的任务就是

- 就是利用 S 选择出一个假设 $h_S \in H$ 使其具有相对于目标概念 c 的较小泛化误差.

泛化误差

给定假设 $h \in H$, 目标概念 $c \in C$, 隐含分布 D , 则 h 的泛化误差或者风险定义为

$$R(h) = \Pr_{x \sim D}[h(x) \neq c(x)] = E_{x \sim D}[I(h(x) \neq c(x))].$$

经验误差

给定假设 $h \in H$, 目标概念 $c \in C$, 样本 $S = \{x_i\}_{i=1}^m$, 则 h 的经验误差或者风险定义为

$$\hat{R}(h) = \frac{1}{m} \sum_{i=1}^m [I(h(x_i) \neq c(x_i))].$$

经验误差与泛化误差的关系:

$$E_{S \sim D^m}[\hat{R}(h)] = R(h).$$

- $O(n)$: $x \in \mathcal{X}$ 的表示代价上界.
- $size(c)$: 概念 c 的表示最大代价.

PAC学习(Probably Approximately Correct (PAC)) Learning

- 目标概念类 C 是PAC可学习的, 是指存在一个学习算法 A 和一个多项式函数 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$ 使得对任意的 $1 > \epsilon, \delta > 0$ 、 \mathcal{X} 上任一分布 D 、任一目标概念 $c \in C$, 下列不等式

$$Pr_{S \sim D^m}(R(h_S) \leq \epsilon) \geq 1 - \delta$$

对任意的样本容量 $m \geq \text{poly}(\frac{1}{\epsilon}, \frac{1}{\delta}, n, \text{size}(c))$ 都成立.

- 进一步, 如果 A 的运行时间也是 $\text{poly}(\frac{1}{\epsilon}, \frac{1}{\delta}, n, \text{size}(c))$, 则称概念类 C 是高效PAC可学习的, 且称 A 为概念类 C 的PAC学习算法.

概要

- 1 Hoeffding不等式
- 2 PAC学习模型
- 3 一致有限假设集情形

- 我们考虑 $|H| < \infty$ ，即有限假设集的情形。
- 如果算法 \mathcal{A} 基于训练数据集 S 选择出的假设 h_S 在 S 上预测误差为0:

$$\hat{R}(h_S) = 0$$

我们就说 h_S 与 S 是一致的。

- 对一致的假设集 H 而言，我们就可以假定目标概念 $c \in H$ 。

定理 1.1

设 H 是从 \mathcal{X} 到 \mathcal{Y} 的有限的映射集. 设算法 \mathcal{A} 对任一目标概念 $c \in H$ 和独立同分布样本集 S , 返回一致假设 $h_S: \hat{R}_S = 0$. 则对任意 $\epsilon, \delta > 0$, 如果 $m \geq \frac{1}{\epsilon}(\log |H| + \log \frac{1}{\delta})$, 不等式

$$Pr_{S \sim D^m}[R(h_S) \leq \epsilon] \geq 1 - \delta$$

成立.

同时, 此样本复杂度保证对任意 $\delta > 0$,

$$R(h_S) \leq \frac{1}{m}(\log |H| + \log \frac{1}{\delta})$$

以至少 $1 - \delta$ 的概率成立.

证明： 固定 $\epsilon > 0$, 考虑下列概率

$$\begin{aligned} & Pr[\exists h \in H : \hat{R}(h) = 0 \wedge R(h) > \epsilon] \\ &= Pr \left[\bigvee_{i=1}^{|H|} (h_i \in H : \hat{R}(h_i) = 0 \wedge R(h_i) > \epsilon) \right] \end{aligned}$$

证明： 固定 $\epsilon > 0$, 考虑下列概率

$$\begin{aligned} & Pr[\exists h \in H : \hat{R}(h) = 0 \wedge R(h) > \epsilon] \\ &= Pr \left[\bigvee_{i=1}^{|H|} (h_i \in H : \hat{R}(h_i) = 0 \wedge R(h_i) > \epsilon) \right] \\ &\leq \sum_{h \in H} Pr \left[\hat{R}(h) = 0 \wedge R(h) > \epsilon \right] \end{aligned}$$

证明： 固定 $\epsilon > 0$, 考虑下列概率

$$\begin{aligned} & Pr[\exists h \in H : \hat{R}(h) = 0 \wedge R(h) > \epsilon] \\ &= Pr \left[\bigvee_{i=1}^{|H|} (h_i \in H : \hat{R}(h_i) = 0 \wedge R(h_i) > \epsilon) \right] \\ &\leq \sum_{h \in H} Pr \left[\hat{R}(h) = 0 \wedge R(h) > \epsilon \right] \\ &\leq \sum_{h \in H} Pr \left[\hat{R}(h) = 0 | R(h) > \epsilon \right] \end{aligned}$$

证明： 固定 $\epsilon > 0$, 考虑下列概率

$$\begin{aligned} & \Pr[\exists h \in H : \hat{R}(h) = 0 \wedge R(h) > \epsilon] \\ &= \Pr\left[\bigvee_{i=1}^{|H|} (h_i \in H : \hat{R}(h_i) = 0 \wedge R(h_i) > \epsilon)\right] \\ &\leq \sum_{h \in H} \Pr\left[\hat{R}(h) = 0 \wedge R(h) > \epsilon\right] \\ &\leq \sum_{h \in H} \Pr\left[\hat{R}(h) = 0 | R(h) > \epsilon\right] \end{aligned}$$

对任一 $R(h) > \epsilon$ 的 $h \in H$ 来说,

$$\Pr\left[\hat{R}(h) = 0 | R(h) > \epsilon\right] \leq (1 - \epsilon)^m.$$

证明： 固定 $\epsilon > 0$, 考虑下列概率

$$\begin{aligned}
 & Pr[\exists h \in H : \hat{R}(h) = 0 \wedge R(h) > \epsilon] \\
 &= Pr\left[\bigvee_{i=1}^{|H|} (h_i \in H : \hat{R}(h_i) = 0 \wedge R(h_i) > \epsilon)\right] \\
 &\leq \sum_{h \in H} Pr\left[\hat{R}(h) = 0 \wedge R(h) > \epsilon\right] \\
 &\leq \sum_{h \in H} Pr\left[\hat{R}(h) = 0 | R(h) > \epsilon\right]
 \end{aligned}$$

对任一 $R(h) > \epsilon$ 的 $h \in H$ 来说,

$$Pr\left[\hat{R}(h) = 0 | R(h) > \epsilon\right] \leq (1 - \epsilon)^m.$$

应用不等式 $1 - x \leq e^{-x}$ 可得到

$$\sum_{h \in H} Pr\left[\hat{R}(h) = 0 | R(h) > \epsilon\right] \leq |H|(1 - \epsilon)^m \leq |H|e^{-m\epsilon}.$$

进一步得到

$$\Pr[\exists h \in H : \hat{R}(h) = 0 \wedge R(h) > \epsilon] \leq |H|e^{-m\epsilon}.$$

令

$$|H|e^{-m\epsilon} \leq \delta,$$

则

$$m \geq \frac{1}{\epsilon}(\log |H| + \log \frac{1}{\delta}),$$

此时

$$\Pr_{S \sim D^m}[R(h_S) \leq \epsilon] \geq 1 - \delta.$$

令 $|H|e^{-m\epsilon} = \delta$, 解得 $1 - \delta$ 的概率成立的泛化误差界

$$R(h_S) \leq \frac{1}{m}(\log |H| + \log \frac{1}{\delta}). \quad \square$$

例：布尔文字的合取

- 布尔变量 x_i : 取值要么为0要么为1.
- 布尔文字: 要么为 x_i , 要么为 \bar{x}_i .
- 目标概念集 C_n : 至多 n 个布尔文字 $x_1/\bar{x}_1, \dots, x_n/\bar{x}_n$ 的合取式的集合.
- 比如对 $n=4$ 来说, 若目标概念为 $x_1 \wedge x_2 \wedge \bar{x}_4$, 则 $(1, 1, 0, 0)$ 为正样本, $(1, 1, 1, 1)$ 为负样本.
- 对正样本 $\mathbf{s} = (s^{(1)}, s^{(2)}, \dots, s^{(n)})$ 来说,
 - 若 $s^{(i)} = 1$, 则目标概念中不可能含有 \bar{x}_i ;
 - 若 $s^{(i)} = 0$, 则目标概念中不可能含有 x_i .

例：布尔文字的合取

构造如下选择一致假设的算法 A :

- (1) 对每个正样本 $\mathbf{s} = (\mathbf{s}^{(1)}, \mathbf{s}^{(2)}, \dots, \mathbf{s}^{(n)})$, 对 $i \in [1, n]$,
 - 若 $\mathbf{s}^{(i)} = 1$, 则将 \bar{x}_i 排除在目标概念类的可能文字之外;
 - 若 $\mathbf{s}^{(i)} = 0$, 则将 x_i 排除在目标概念类的可能文字之外.
- (2) 没有被排除的所有文字的合取就是和目标概念一致的假设.

例如考虑 $\mathbf{S} = (\mathbf{s}_1, \mathbf{s}_2, \mathbf{s}_3)$, 其中

- 正样本:
 - $\mathbf{s}_1 = (1, 0, 1, 0)$: 排除 $\bar{x}_1, x_2, \bar{x}_3, x_4$;
 - $\mathbf{s}_2 = (1, 1, 0, 0)$: 排除 $\bar{x}_1, \bar{x}_2, x_3, x_4$.
- 负样本:
 - $\mathbf{s}_3 = (0, 0, 1, 0)$.

由此返回假设 $x_1 \wedge \bar{x}_4$.

例：布尔文字的合取

- 我们以至多由 n 个布尔文字的合取式的集合作为假设集 H .
- $|H| = |C_n| = 3^n$.
- 则由上述定理可知对任意 $\epsilon, \delta > 0$, 得到如下样本复杂度的界:

$$m \geq \frac{1}{\epsilon} (n \log 3 + \log \frac{1}{\delta}).$$

因此，至多由 n 个布尔文字的合取式构成的概念类是PAC可学习的。

概要

- 1 Hoeffding不等式
- 2 PAC学习模型
- 3 一致有限假设集情形
- 4 不一致有限假设集情形

- 考虑 $|H| < \infty$, 即有限假设集的情形.
- 对更一般的情形来说, H 中未必有假设和训练样本集一致,即

$$\hat{R}(h_S) = 0$$

未必满足.

- 其实不一致($\hat{R}(h_S) > 0$)是更典型的情形.

Hoeffding不等式回顾

Hoeffding不等式：关于 $\frac{1}{m}S_m - E[\frac{1}{m}S_m] \geq \epsilon$ 的概率界

设 X_1, \dots, X_m 为一组独立随机变量且满足 $0 \leq X_i \leq 1$, 则对任意 $\epsilon > 0$, 下列不等式成立:

$$(1.) \Pr[\frac{1}{m} \sum_{i=1}^m X_i - \frac{1}{m} \sum_{i=1}^m E[X_i] \geq \epsilon] \leq \exp(-2m\epsilon^2).$$

$$(2.) \Pr[|\frac{1}{m} \sum_{i=1}^m X_i - \frac{1}{m} \sum_{i=1}^m E[X_i]| \geq \epsilon] \leq 2 \exp(-2m\epsilon^2).$$

推论 1.1

固定 $\epsilon > 0$, 且设 S 为容量为 m 的独立同分布样本集, 则对任意假设 $h: \mathcal{X} \rightarrow \{0, 1\}$, 下列不等式成立

- $Pr_{S \sim D^m}[\hat{R}(h) - R(h) \geq \epsilon] \leq e^{-2m\epsilon^2}.$
- $Pr_{S \sim D^m}[\hat{R}(h) - R(h) \leq -\epsilon] \leq e^{-2m\epsilon^2}.$
- $Pr_{S \sim D^m}[|\hat{R}(h) - R(h)| \geq \epsilon] \leq 2e^{-2m\epsilon^2}.$

推论 1.2 单个假设的泛化误差界

固定一个假设 $h: \mathcal{X} \rightarrow \{0, 1\}$, 则对任意 $\delta > 0$, 下列不等式至少以 $1 - \delta$ 的概率成立:

$$R(h) \leq \hat{R}(h) + \sqrt{\frac{\log \frac{2}{\delta}}{2m}}.$$

证明概要: 令

$$\delta \geq 2e^{-2m\epsilon^2},$$

则

$$\begin{aligned} & Pr_{S \sim D^m}[R(h) \leq \hat{R}(h) + \epsilon] \\ & \geq Pr_{S \sim D^m}[|\hat{R}(h) - R(h)| \leq \epsilon] \\ & \geq 1 - \delta. \end{aligned}$$

我们考虑一个硬币投掷问题：

- 正面出现的概率为 p ,
- 假设 h 的预测总是反面:
 - h 的泛化误差 $R(h) = p$;
 - h 的经验误差 $\hat{R}(h) = \hat{p}$.
- 由上面的推论可知

$$|p - \hat{p}| \leq \sqrt{\frac{\log \frac{2}{\delta}}{2m}}$$

至少以概率 $1 - \delta$ 成立.

- 我们选择 $\delta = 0.02$, $m = 500$, 则

$$|p - \hat{p}| \leq \sqrt{\frac{\log \frac{2}{0.02}}{2 \times 500}} \approx 0.068$$

至少以概率98%成立.

定理 1.2

设 H 为有限假设集, 则对任意 $\delta > 0$, 下列不等式至少以概率 $1 - \delta$ 成立:

$$\forall h \in H, R(h) \leq \hat{R}(h) + \sqrt{\frac{\log |H| + \log \frac{2}{\delta}}{2m}}.$$

证明概要:

$$\begin{aligned} & Pr[\exists h \in H \text{ s.t. } |\hat{R}(h) - R(h)| > \epsilon] \\ = & Pr[\vee_{h \in H} (|\hat{R}(h) - R(h)| > \epsilon)] \\ \leq & \sum_{h \in H} Pr[|\hat{R}(h) - R(h)| > \epsilon] \\ \leq & 2|H|e^{-2m\epsilon^2}. \end{aligned}$$

令

$$\delta = 2|H|e^{-2m\epsilon^2},$$

得到

$$\epsilon = \sqrt{\frac{\log |H| + \log \frac{2}{\delta}}{2m}}. \quad \square$$

- 对有限假设集 H 来说,

$$R(h) \leq \hat{R}(h) + \sqrt{\frac{\log |H| + \log \frac{2}{\delta}}{2m}}.$$

$$R(h) \leq \hat{R}(h) + O\left(\sqrt{\frac{\log_2 |H|}{m}}\right).$$

- 对有限假设集 H 的一致情形来说,

$$R(h_S) \leq \frac{1}{m}(\log |H| + \log \frac{1}{\delta})$$

$$R(h_S) \leq O\left(\frac{\log_2 |H|}{m}\right).$$

概要

- 1 Hoeffding不等式
- 2 PAC学习模型
- 3 一致有限假设集情形
- 4 不一致有限假设集情形
- 5 不可知PAC学习

- 在更一般的情形中，通常假定 $S = \{(x_i, y_i)\}_{i=1}^m$ 依 $\mathcal{X} \times \mathcal{Y}$ 上的分布 D 独立采样得到.
- 这种情形通常被称为随机情形(stochastic scenarios).
- 任一 $h \in H$, h 的泛化误差定义为

$$\begin{aligned} R(h) &= Pr_{(x,y) \sim D}[h(x) \neq y] \\ &= E_{(x,y) \sim D}[I(h(x) \neq y)]. \end{aligned}$$

不可知PAC学习(Agnostic PAC-Learning)

- 设 H 为假设集. \mathcal{A} 称为一个不可知PAC学习算法,是指存在一个多项式函数 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$ 使得对任意的 $1 > \epsilon, \delta > 0$ 、 $\mathcal{X} \times \mathcal{Y}$ 上任一分布 D , 下列不等式

$$\Pr_{S \sim D^m}[R(h_S) - \min_{h \in H} R(h) \leq \epsilon] \geq 1 - \delta$$

对任意的样本容量 $m \geq \text{poly}(\frac{1}{\epsilon}, \frac{1}{\delta}, n, \text{size}(c))$ 都成立.

- 进一步, 如果 \mathcal{A} 的运行时间也是 $\text{poly}(\frac{1}{\epsilon}, \frac{1}{\delta}, n, \text{size}(c))$, 则称 \mathcal{A} 为高效不可知PAC学习算法.

- 对于确定(deterministic)的情形来说, 一个数据点的标记由可测函数 c 唯一确定 (以概率1) .
- 因此, 只考虑按照 \mathcal{X} 上的分布 D 来抽样数据

$$S = \{x_i\}_{i=1}^m.$$

- x_i 的标记通过

$$c(x_i) = y_i$$

得到。

- 对目标函数 c 来说,

$$R(c) = 0.$$

贝叶斯误差(Bayes Error)

- 给定 $\mathcal{X} \times \mathcal{Y}$ 上的分布 D , 贝叶斯误差 R^* 被定义为 \mathcal{X} 到 \mathcal{Y} 的可测函数的误差的下确界:

$$R^* = \inf_{h: \mathcal{X} \rightarrow \mathcal{Y}} R(h).$$

- 如果假设 h 满足 $R(h) = R^*$, 则称 h 为贝叶斯假设或者贝叶斯分类器, 通常表示为 h_{Bayes} .
- $\forall x \in \mathcal{X}, h_{\text{Bayes}}(x) = \operatorname{argmax}_{y \in \{0,1\}} \Pr[y|x]$.
- h_{Bayes} 在 $x \in \mathcal{X}$ 的预测误差为 $\min\{\Pr[0|x], \Pr[1|x]\}$.
- 给定 $\mathcal{X} \times \mathcal{Y}$ 上的分布 D , 在点 $x \in \mathcal{X}$ 的噪声定义为

$$\text{noise}(x) = \min\{\Pr[1|x], \Pr[0|x]\}.$$

- $\text{noise} = E[\text{noise}(x)] = R^*$

- 给定假设集 H , 则对 $h \in H$ 来说,

$$R(h) - R^* = R(h) - R(h^*) + R(h^*) - R^*,$$

这里 $R(h^*) = \inf_{h \in H} R(h)$, h^* 是 H 中具有最小误差的假设。

- $R(h^*) - R^*$ 为逼近误差(Approximation error), 刻画了假设集 H 逼近贝叶斯误差的程度.
- $R(h) - R(h^*)$ 为估计误差(Estimation error), 刻画了假设 h 相对于 h^* 的质量.
- 不可知PAC可学习就是基于估计误差的.

- h_S^{ERM} 为依据经验风险最小化(Empirical Risk Minimization)策略基于训练集 S 选择的假设:

$$h_S^{ERM} = \operatorname{argmin}_{h \in H} \hat{R}_S(h).$$

- 则

$$\begin{aligned} R(h_S^{ERM}) - R(h^*) &= R(h_S^{ERM}) - \hat{R}(h_S^{ERM}) + \hat{R}(h_S^{ERM}) - R(h^*) \\ &\leq R(h_S^{ERM}) - \hat{R}(h_S^{ERM}) + \hat{R}(h^*) - R(h^*) \\ &\leq 2 \sup_{h \in H} |R(h) - \hat{R}(h)| \end{aligned}$$

- 回顾 $R(h) \leq \hat{R}(h) + O\left(\sqrt{\frac{\log_2 |H|}{m}}\right)$, 则随着 $|H|$ 的增大, 右端增大, 而 $R(h^*)$ 减少。

小结

- 1 Hoeffding不等式
- 2 PAC学习模型
- 3 一致有限假设集情形
- 4 不一致有限假设集情形
- 5 不可知PAC学习